

Relatório Técnico

Classificação de Imagens com Redes Convolucionais no Dataset CUHK Face Sketch Database

Autores: Maick Vieira Alves e Willian Rullian Ferreira dos Anjos

Data: [Insira a data aqui]

1. Resumo

Este relatório apresenta um estudo detalhado sobre a implementação de uma rede neural convolucional (CNN) para a tarefa de classificação de imagens faciais no dataset CUHK Face Sketch Database (CUFS). A atividade envolveu a preparação do conjunto de dados, o desenvolvimento de uma arquitetura personalizada de CNN, e a análise dos resultados utilizando métricas como F1-Score, curva ROC e AUC-ROC. O projeto também examina os desafios relacionados a datasets limitados e desbalanceados, refletindo sobre os erros de classificação e explorando estratégias de mitigação para problemas comuns em aprendizado profundo.

2. Introdução

A classificação de imagens é uma tarefa fundamental em visão computacional, com aplicações que abrangem segurança, saúde, automação e entretenimento. Redes neurais convolucionais (CNNs) têm revolucionado esse campo ao permitir a extração automática de características relevantes diretamente dos dados de imagem, substituindo abordagens tradicionais de engenharia manual de características.

Neste projeto, utilizamos o CUHK Face Sketch Database (CUFS) para classificar imagens de rostos humanos segundo o sexo biológico. Este dataset apresenta desafios únicos, incluindo a variação na qualidade das

Classificação de Imagens com Redes Convolucionais no Dataset CUHK Face Sketch Database

imagens e o número limitado de amostras. A implementação de uma CNN personalizada permite explorar as nuances dos dados enquanto enfrentamos os desafios do treinamento de modelos a partir do zero.

3. Metodologia

3.1 Preparação dos Dados

A preparação dos dados envolveu várias etapas críticas para garantir a qualidade do modelo de classificação:

- Redimensionamento das imagens para 250x200 pixels, uniformizando as dimensões para entrada na CNN.
- Normalização dos valores RGB das imagens para o intervalo $[0, 1]$, melhorando a estabilidade do treinamento.
- Rotulação manual dos dados: 0 para masculino e 1 para feminino, garantindo consistência e precisão na classificação.

3.2 Divisão do Dataset

Para garantir uma avaliação robusta, o dataset foi dividido em:

- Treinamento (50%): Para aprendizado do modelo.
- Validação (30%): Para ajustes de hiperparâmetros.
- Teste (20%): Para avaliação final. Seed fixa (23) foi usada para reprodutibilidade.

3.3 Modelo CNN

O modelo desenvolvido apresenta as seguintes características:

- Camadas convolucionais com filtros de tamanhos variados (3x3, 5x5) para captura de detalhes finos e estruturas globais das imagens.
- Camadas de pooling (max-pooling) para redução da dimensionalidade, preservando informações essenciais.
- Dropout (taxa de 0.3) para reduzir overfitting e melhorar a generalização.
- Função de ativação ReLU para não-linearidades e softmax na saída para probabilidade de classes.

3.4 Treinamento e Avaliação

O treinamento foi realizado utilizando a função de perda de entropia cruzada binária e o otimizador Adam. As métricas de avaliação incluem precisão, recall, F1-Score, curva ROC e AUC-ROC.

4. Discussão

4.1 Resultados e Erros

Os resultados indicaram que o modelo alcançou um bom desempenho geral, com F1-Score indicando equilíbrio entre precisão e recall. No entanto, erros de classificação ocorreram, particularmente em imagens com condições de iluminação atípicas ou ângulos desfavoráveis. Isso sugere a necessidade de mais robustez em dados não padronizados.

4.2 Limitações do Dataset

O CUFS, apesar de útil, apresenta limitações que impactaram os resultados:

- Número limitado de amostras por classe, dificultando o aprendizado do modelo.
- Possível desbalanceamento entre classes masculino e feminino.
- Variabilidade de qualidade nas imagens, incluindo ruído e resolução inconsistente.

4.3 Melhorias Sugeridas

Para mitigar esses problemas, recomenda-se:

- Aplicação de técnicas de data augmentation, como rotações, flips e ajustes de iluminação.
- Teste de arquiteturas mais profundas ou complexas, como redes residuais (ResNet).
- Uso de técnicas de regularização adicionais, como L2 regularization, para melhorar a generalização.

5. Conclusão e Trabalhos Futuros

Classificação de Imagens com Redes Convolucionais no Dataset CUHK Face Sketch Database

Este trabalho explorou a aplicação de redes convolucionais para classificação de imagens faciais no dataset CUHK Face Sketch Database (CUFS). O modelo apresentou um desempenho satisfatório, destacando a capacidade das CNNs de aprender representações úteis mesmo em condições desafiadoras.

No entanto, as limitações do dataset impuseram barreiras ao treinamento ideal do modelo. Aprendizados futuros incluem a aplicação de técnicas avançadas de data augmentation, treinamento em datasets maiores e exploração de arquiteturas modernas. Este estudo reforça a importância de dados de alta qualidade e modelos personalizados para tarefas específicas de classificação.

6. Referências

- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Chollet, F. (2018). Deep Learning with Python. Manning Publications.
- Kaggle Dataset: CUHK Face Sketch Database (CUFS).